

# Chap 8 参数估计

统计  
推断  
的  
基本  
问题

参数估计  
(Chap8)

假设检验  
(Chap9)

点估计

区间估计

## § 8.1 参数的点估计

### 什么是参数估计？

例如， $X \sim N(\mu, \sigma^2)$ ,

若 $\mu, \sigma^2$ 未知，在抽取样本、获取样本观测值之后，

通过构造样本的函数(统计量)，给出它们的  
估**计值或取值区间**，就是参数估计的内容.

点估计

区间估计

# 参数估计的类型

**点估计** —— 估计未知参数的值

**区间估计** —— 估计未知参数的取值范围，  
使得这个范围包含未知参数  
真值的概率为给定的值.

## §8.1 点估计方法

### 点估计的思想方法

设总体  $X$  的分布函数的形式已知，但它含有一个或多个未知参数： $\theta_1, \theta_2, \dots, \theta_k$

设  $X_1, X_2, \dots, X_n$  为总体的一个样本

构造  $k$  个统计量：

$$\theta_1(X_1, X_2, \dots, X_n)$$

$$\theta_2(X_1, X_2, \dots, X_n)$$

.....

$$\theta_k(X_1, X_2, \dots, X_n)$$



随机变量

当测得一组样本值 $(x_1, x_2, \dots, x_n)$ 时，代入上述统计量，即可得到  $k$  个数：

$$\left. \begin{array}{l} \hat{\theta}_1(x_1, x_2, \dots, x_n) \\ \hat{\theta}_2(x_1, x_2, \dots, x_n) \\ \cdots \cdots \cdots \cdots \\ \hat{\theta}_k(x_1, x_2, \dots, x_n) \end{array} \right\} \text{数值}$$

称数 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  为未知参数 $\theta_1, \theta_2, \dots, \theta_k$  的**估计值**  
称对应的统计量  $\theta_1(X_1, X_2, \dots, X_n), \theta_2(X_1, X_2, \dots, X_n),$

$$\dots, \theta_k(X_1, X_2, \dots, X_n)$$

为未知参数  $\theta_1, \theta_2, \dots, \theta_k$  的**估计量**

## 问题

如何构造统计量？

如何评价估计量的好坏？

# 常用的点估计方法

## 口 矩法

方法：用样本的  $k$  阶矩作为总体的  $k$  阶矩的估计量，建立含有待估计参数的方程，从而可解出待估计参数

即：

$$\frac{1}{n} \sum_{i=1}^n X_i \rightarrow E(X)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 \rightarrow E(X^2)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^3 \rightarrow E(X^3)$$

记作：

$$\frac{1}{n} \sum_{i=1}^n X_i = \hat{E}(X)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{E}(X^2)$$

$$\frac{1}{n} \sum_{i=1}^n X_i^3 = \hat{E}(X^3)$$

由

$$\left\{ \begin{array}{l} \frac{1}{n} \sum_{i=1}^n X_i = \hat{E}(X) \\ \frac{1}{n} \sum_{i=1}^n X_i^2 = \hat{E}(X^2) \end{array} \right.$$

→  $\hat{\mu} = \hat{E}(X) = \bar{X}$

$$\hat{\sigma}^2 = \hat{E}(X^2) - \hat{E}^2(X) = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

$$= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

即：以样本均值估计总体均值，  
以样本的2阶中心距估计方差

**例2** 设总体  $X \sim N(\mu, \sigma^2)$ ,  $X_1, X_2, \dots, X_n$  为总体的样本, 求  $\mu, \sigma^2$  的矩法估计量。

**解**  $\hat{\mu}_{\text{矩}} = \hat{E}(X) = \bar{X}$

$$\hat{\sigma}_{\text{矩}}^2 = \hat{E}(X^2) - \hat{E}^2(X) = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$$

$$= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

**例3** 设总体  $X \sim E(\lambda)$ ,  $X_1, X_2, \dots, X_n$  为总体的样本,  
求  $\lambda$  的矩法估计量。

**解**  $E(X) = \frac{1}{\lambda}$       则  $\hat{E}(X) = \frac{1}{\hat{\lambda}} = \bar{X}$

故  $\hat{\lambda} = \frac{1}{\bar{X}}$

## 口 点估计的极大似然估计法

思想方法：一次试验就出现的事件有较大的概率

例如：有两个外形相同的箱子，都装有100个球

第一箱 99个白球， 1个红球

第二箱 1个白球， 99个红球

现从两箱中任取一箱，并从箱中任取一球，结果所取得的球是白球。

问 所取的球来自哪一箱？

答 第一箱。

**例6** 设总体  $X$  服从0-1分布，且  $P(X = 1) = p$ ，  
用极大似然法求  $p$  的估计值。

**解**  $X$  的概率分布为

$$P(X = 1) = p,$$

$$P(X = 0) = 1-p,$$

可以写成

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x = 0, 1$$

设  $X_1, X_2, \dots, X_n$  为总体  $X$  的样本,

设  $x_1, x_2, \dots, x_n$  为总体  $X$  的样本值,

则

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$

$$= P(X_1 = x_1) \cdot P(X_2 = x_2) \cdots \cdots P(X_n = x_n)$$

$$= p^{x_1} (1-p)^{1-x_1} \cdot p^{x_2} (1-p)^{1-x_2} \cdots \cdots p^{x_n} (1-p)^{1-x_n}$$

$$= p^{\sum_{i=1}^n x_i} (1-p)^{n - \sum_{i=1}^n x_i}$$

$$\equiv L(p)$$

$$x_i = 0, 1, i = 1, 2, \dots, n$$

$$\frac{d \ln L}{dp} = \frac{\sum_{i=1}^n x_i}{p} - \frac{n - \sum_{i=1}^n x_i}{1-p} = 0 \quad \text{令} \quad \Rightarrow \hat{p} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$$

$$\left. \frac{d^2 \ln L}{dp^2} = -\frac{\sum_{i=1}^n x_i}{p^2} - \frac{n - \sum_{i=1}^n x_i}{(1-p)^2} < 0 \right\}$$

所以  $\hat{p} = \bar{x}$  为所求  $p$  的估计值.

一般地，设 $X$ 为离散型随机变量，其分布律为

$$P(X = x) = f(x, \theta), \quad x = u_1, u_2, \dots, \theta \in \Theta$$

$X_1, X_2, \dots, X_n$ 为总体 $X$ 的样本，

$x_1, x_2, \dots, x_n$ 为总体 $X$ 的样本值，

则 $X_1, X_2, \dots, X_n$ 的概率分布为

$$\begin{aligned} & P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) \\ &= f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta) \end{aligned}$$

记为

$$= L(x_1, x_2, \dots, x_n, \theta) \stackrel{\text{或}}{=} L(\theta) \quad x_i = u_1, u_2, \dots,$$

$$i = 1, 2, \dots, n, \theta \in \Theta$$

称 $L(\theta)$ 为样本的似然函数

当给定一组样本值时， $L(\theta)$ 就是参数 $\theta$ 的函数，极大似然估计法的思想就是：

选择适当的 $\theta = \hat{\theta}$ ，使 $L(\theta)$ 取最大值，即

$$\begin{aligned} & L(x_1, x_2, \dots, x_n, \hat{\theta}) \\ &= \max_{\theta \in \Theta} \{f(x_1, \theta) f(x_2, \theta) \cdots f(x_n, \theta)\} \end{aligned}$$

则称这样得到的 $\hat{\theta}$

$$\hat{\theta} = g(x_1, x_2, \dots, x_n)$$

为参数 $\theta$ 的极大似然估计值

称统计量

$$\hat{\theta} = g(X_1, X_2, \dots, X_n)$$

为参数 $\theta$ 的极大似然估计量

**注1** 若随机变量 $X$ 连续, 取 $f(x_i, \theta)$ 为 $X_i$  的密度函数

似然函数为  $L(\theta) = \prod_{i=1}^n f(x_i, \theta)$

**注2** 未知参数个数可以不止一个, 如 $\theta_1, \theta_2, \dots, \theta_k$

设 $X$  的密度函数(或分布率)为  $f(x, \theta_1, \theta_2, \dots, \theta_k)$   
则定义似然函数为

$$L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$$

$$= L(\theta_1, \theta_2, \dots, \theta_k) = \prod_{i=1}^n f(x_i, \theta_1, \theta_2, \dots, \theta_k)$$

$$-\infty < x_i < +\infty, i = 1, 2, \dots, n \quad (\theta_1, \theta_2, \dots, \theta_k) \in \Theta$$

若  $L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)$  关于  $\theta_1, \theta_2, \dots, \theta_k$  可微，则称

$$\frac{\partial}{\partial \theta_r} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0 \quad r = 1, 2, \dots, k$$

为似然方程组

若对于某组给定的样本值  $x_1, x_2, \dots, x_n$ ，  
参数  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  使得似然函数取得最大值，即

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k) \\ = \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\}$$

则称  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  为  $\theta_1, \theta_2, \dots, \theta_k$  的极大似然估计值

显然 ,

$$\hat{\theta}_r = g_r(x_1, x_2, \dots, x_n) \quad r = 1, 2, \dots, k$$

称统计量

$$\hat{\theta}_r = g_r(X_1, X_2, \dots, X_n) \quad r = 1, 2, \dots, k$$

为  $\theta_1, \theta_2, \dots, \theta_k$  的极大似然估计量

**例7** 设总体  $X \sim N(\mu, \sigma^2)$ ,  $x_1, x_2, \dots, x_n$  是  $X$  的一组样本值, 求  $\mu, \sigma^2$  的极大似然估计.

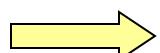
**解**  $L(x_1, x_2, \dots, x_n; \mu, \sigma^2)$

$$= \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i-\mu)^2}{2\sigma^2}} = \frac{1}{(2\pi)^{\frac{n}{2}} (\sigma^2)^{\frac{n}{2}}} e^{-\sum_{i=1}^n \frac{(x_i-\mu)^2}{2\sigma^2}}$$

$$\ln L = -\sum_{i=1}^n \frac{(x_i - \mu)^2}{2\sigma^2} - \frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln(\sigma^2)$$

似然  
方程  
组为

$$\left\{ \begin{array}{l} \left( \frac{\partial}{\partial \mu} \ln L \right) = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \\ \left( \frac{\partial}{\partial (\sigma^2)} \ln L \right) = \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 - \frac{n}{2(\sigma^2)} = 0 \end{array} \right.$$



$$\left\{ \begin{array}{l} \hat{\mu}_{mle} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x} \\ \hat{\sigma^2}_{mle} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \end{array} \right.$$

$\mu, \sigma^2$  的极大似然估计量分别为

$$\frac{1}{n} \sum_{i=1}^n X_i = \bar{X} \quad \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = S_n^2$$

# 求未知参数的极大似然估计值(量)的方法

1 ) 写出似然函数  $L$

2 ) 求出  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$  , 使得

$$L(x_1, x_2, \dots, x_n; \hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k)$$

$$= \max_{(\theta_1, \theta_2, \dots, \theta_k) \in \Theta} \{L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k)\}$$

**若**  $L$  是  $\theta_1, \theta_2, \dots, \theta_k$  的可微函数, 解似然方程组

$$\frac{\partial}{\partial \theta_r} L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_k) = 0$$

$$r = 1, 2, \dots, k$$

可求得未知参数的极大似然估计值  $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$

然后, 再求得极大似然估计量.

**若**  $L$  不是  $\theta_1, \theta_2, \dots, \theta_k$  的可微函数, 需用其它方法求极大似然估计值. 请看下例 :

**例8** 设  $X \sim U(a,b)$ ,  $x_1, x_2, \dots, x_n$  是  $X$  的一个样本, 求  $a, b$  的极大似然估计值与极大似然估计量.

**解**  $X$  的密度函数为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a < x < b \\ 0, & \text{其它} \end{cases}$$

似然函数为

$$L(x_1, x_2, \dots, x_n; a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a < x_i < b, \\ 0, & i = 1, 2, \dots, n \\ & \text{其它} \end{cases}$$

似然函数只有当  $a < x_i < b, i = 1, 2, \dots, n$  时才能获得最大值, 且  $a$  越大,  $b$  越小,  $L$  越大.

令  $x_{\min} = \min \{x_1, x_2, \dots, x_n\}$   
 $x_{\max} = \max \{x_1, x_2, \dots, x_n\}$

取  $\hat{a} = x_{\min}, \quad \hat{b} = x_{\max}$

则对满足  $a \leq x_{\min} \leq x_{\max} \leq b$  的一切  $a < b$ , 都有

$$\frac{1}{(b-a)^n} \leq \frac{1}{(x_{\max} - x_{\min})^n}$$

故  $\hat{a} = x_{\min}, \hat{b} = x_{\max}$

是  $a, b$  的极大似然估计值.

$$X_{\min} = \min \{X_1, X_2, \dots, X_n\}$$

$$X_{\max} = \max \{X_1, X_2, \dots, X_n\}$$

分别是  $a, b$  的极大似然估计量.

## 极大似然估计值的不变性原理

设  $\hat{\theta}$  是  $\theta$  的极大似然估计值,  $u(\theta)$  ( $\theta \in \Theta$ ) 是  $\theta$  的函数, 且具有单值的反函数  $\theta = \theta(u)$ ,  $u \in U$  则  $\hat{u} = u(\hat{\theta})$  是  $u(\theta)$  的极大似然估计值.

如：在正态分布总体  $N(\mu, \sigma^2)$  中， $\sigma^2$  的极大似然估计值为

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

$\sigma = \sqrt{\sigma^2}$  是  $\sigma^2$  的单值函数，且具有单值的反函数，故  $\sigma$  的极大似然估计值为

$$\hat{\sigma} = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$\lg \sigma$  的极大似然估计值为

$$\hat{\lg \sigma} = \lg \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$$

$$P(X > t) = \int_{-\infty}^t \frac{1}{\sqrt{2\pi} \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}} e^{-\frac{(x-\bar{x})^2}{2 \cdot \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}} dx$$

矩估计就不具有这个性质.

例如 设  $X$  的密度函数为

$$f(x) = \begin{cases} \sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-\frac{x^2}{2\sigma^2}} & x > 0 \\ 0 & x \leq 0 \end{cases}$$

$$E(X) = \sqrt{\frac{2}{\pi}} \sigma, \quad D(X) = \left(1 - \frac{2}{\pi}\right) \sigma^2$$

$X_1, X_2, \dots, X_n$  为总体的样本

由矩法，令

$$E(X) = \sqrt{\frac{2}{\pi}} \sigma = \bar{X}$$

$$E(X^2) = D(X) + E^2(X) = \sigma^2 = \frac{1}{n} \sum_{i=1}^n X_i^2$$

得 $\sigma$ 与 $\sigma^2$ 的矩法估计量为

$$\hat{\sigma} = \sqrt{\frac{\pi}{2}} \bar{X} \quad \text{——不具有不变性}$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 \neq (\hat{\sigma})^2$$

## § 8.2 点估计的评价标准

对于同一个未知参数, 不同的方法得到的估计量可能不同, 于是提出问题

- 1、应该选用哪一种估计量?
- 2、用什么标准来评价一个估计量的好坏?

**常用  
标准** {

- (1) 无偏性
- (2) 有效性
- (3) 一致性

## ○ 无偏性

**定义** 设  $(X_1, X_2, \dots, X_n)$  是总体  $X$  的样本 ,

$\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  是总体参数  $\theta$  的估计量 ,

$E(\hat{\theta})$  存在, 如果 :

$$E(\hat{\theta}) = \theta$$

则称  $\hat{\theta}$  是  $\theta$  的无偏估计量.

**例1** 设总体 $X$ 的  $k$  阶矩  $\mu_k = E(X^k)$  存在 ,

$(X_1, X_2, \dots, X_n)$  是总体 $X$ 的样本 ,

**求证 :** 不论  $X$  服从什么分布,

$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$  是  $\mu_k$  的无偏估计量

**证** 由于  $E(X_i^k) = \mu_k \quad i = 1, 2, \dots, n$  因而

$$E(A_k) = E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k)$$

$$= \frac{1}{n} \cdot n \cdot \mu_k = \mu_k$$

特別地,

样本均值  $\bar{X}$  是总体期望  $E(X)$  的无偏估计量

样本二阶原点矩  $A_2 = \frac{1}{n} \sum_{i=1}^n X_i^2$

是总体二阶原点矩  $\mu_2 = E(X^2)$  的无偏估计量

**例2** 设总体  $X$  的期望  $E(X)$  与方差  $D(X)$  存在,  
 $(X_1, X_2, \dots, X_n)$  是  $X$  的一个样本,  $n > 1$ . 求证:

(1)  $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$  不是  $D(X)$  的无偏估计量

(2)  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$  是  $D(X)$  的无偏估计量

**证** 前已证  $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2$

$$E(X_i) = E(X) = \mu, \quad D(X_i) = D(X) = \sigma^2$$

$$E(\bar{X}) = E(X) = \mu, \quad D(\bar{X}) = \frac{\sigma^2}{n}$$

因而

$$\begin{aligned}
 E\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right) &= E\left(\frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}^2\right) \\
 E(X_i^2) &= E^2(X_i) + D(X) \\
 = \frac{1}{n} \sum_{i=1}^n E(X_i^2) - E(\bar{X}^2) &= \mu^2 + \sigma^2 \\
 E(\bar{X}^2) &= E^2(\bar{X}_i) + D(\bar{X}) \\
 = (\sigma^2 + \mu^2) - \left(\frac{\sigma^2}{n} + \mu^2\right) &= \mu^2 + \frac{\sigma^2}{n} \\
 = \frac{n-1}{n} \sigma^2 &\neq \sigma^2
 \end{aligned}$$

故

$$E\left(\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right) = \sigma^2 \quad \text{证毕.}$$

通常，在估计时：  
确实以样本均值估计总体均值

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}$$

但却不以2阶中心距  $S_n^2$  估计总体方差，  
而是以样本方差  $S^2$  估计总体方差

$$\hat{\sigma}^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2$$

## ○ 有效性

**定义** 设  $\hat{\theta}_1 = \theta_1(X_1, X_2, \dots, X_n)$

$\hat{\theta}_2 = \theta_2(X_1, X_2, \dots, X_n)$

都是总体参数  $\theta$  的无偏估计量, 且

$$D(\hat{\theta}_1) < D(\hat{\theta}_2)$$

则称  $\hat{\theta}_1$  比  $\hat{\theta}_2$  更有效

**例** 设总体期望为  $E(X) = \mu$ , 方差  $D(X) = \sigma^2$ ,

$(X_1, X_2, \dots, X_n)$  为总体  $X$  的一个样本 ,

(1) 设常数  $c_i \neq \frac{1}{n} \quad i = 1, 2, \dots, n. \quad \sum_{i=1}^n c_i = 1.$

求证  $\hat{\mu}_1 = \sum_{i=1}^n c_i X_i$  是  $\mu$  的无偏估计量

(2) 求证  $\hat{\mu} = \bar{X}$  比  $\hat{\mu}_1 = \sum_{i=1}^n c_i X_i$  更有效

**证:** (1) 
$$\begin{aligned} E(\hat{\mu}_1) &= \sum_{i=1}^n c_i E(X_i) \\ &= \sum_{i=1}^n c_i \mu = \mu \sum_{i=1}^n c_i = \mu \end{aligned}$$

(2) 
$$\begin{aligned} D(\hat{\mu}) &= D(\bar{X}) = \frac{1}{n} \sigma^2 \\ D(\hat{\mu}_1) &= D\left(\sum_{i=1}^n c_i X_i\right) = \sum_{i=1}^n D(c_i X_i) \\ &= \sum_{i=1}^n c_i^2 D(X_i) = \sigma^2 \sum_{i=1}^n c_i^2 \end{aligned}$$

证明  $\hat{\mu} = \bar{X}$  比  $\hat{\mu}_1 = \sum_{i=1}^n c_i X_i$  更有效

只需  $D(\hat{\mu}) < D(\hat{\mu}_1)$  即  $\frac{1}{n} < \sum_{i=1}^n c_i^2$

$$\begin{aligned}
 \text{而} \quad 1 &= \left( \sum_{i=1}^n c_i \right)^2 = \sum_{i=1}^n c_i^2 + 2 \sum_{1 \leq i < j \leq n} c_i c_j \\
 &\leq \sum_{i=1}^n c_i^2 + \sum_{1 \leq i < j \leq n} (c_i^2 + c_j^2) = n \sum_{i=1}^n c_i^2
 \end{aligned}$$

→  $\frac{1}{n} \leq \sum_{i=1}^n c_i^2$

“=” 成立当且仅当  $c_1 = c_2 = \dots = c_n$

→  $D(\hat{\mu}) < D(\hat{\mu}_1)$

**结论** 算术均值比加权均值更有效。

算术均值是所有线性无偏估计中方差最小的，称为最小方差无偏估计。

例如  $X \sim N(\mu, \sigma^2)$ ,  $(X_1, X_2)$  是一样本

$$\left. \begin{array}{l} \hat{\mu}_1 = \frac{2}{3}X_1 + \frac{1}{3}X_2 \\ \hat{\mu}_2 = \frac{1}{4}X_1 + \frac{3}{4}X_2 \\ \hat{\mu}_3 = \frac{1}{2}X_1 + \frac{1}{2}X_2 \end{array} \right\} \text{都是 } \mu \text{ 的无偏估计量}$$

例7(2) 知  $\hat{\mu}_3$  最有效.

## ● 一致性

**定义** 设  $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$  是总体参数  $\theta$  的估计量. 若对于任意的  $\theta \in \Theta$ , 当  $n \rightarrow \infty$  时,  $\hat{\theta}$  依概率收敛于  $\theta$ , 即  $\forall \varepsilon > 0$ ,

$$\lim_{n \rightarrow \infty} P(|\hat{\theta} - \theta| \geq \varepsilon) = 0$$

则称  $\hat{\theta}$  是总体参数  $\theta$  的一致(或相合)估计量.

一致性估计量仅在样本容量  
 $n$  足够大时, 才显示其优越性.

**例6** 样本k阶矩  $\frac{1}{n} \sum_{i=1}^n X_i^k$  是总体k阶矩  $E(X^k)$   
的一致估计

$$\text{证明 : } E\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right) = \frac{1}{n} \sum_{i=1}^n E(X_i^k) = E(X^k)$$

$$\begin{aligned} \text{故 , } 1 &\geq P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i^k - E(X^k)\right| < \varepsilon\right\} \geq 1 - \frac{D\left(\frac{1}{n} \sum_{i=1}^n X_i^k\right)}{\varepsilon^2} \\ &= 1 - \frac{D\left(\sum_{i=1}^n X_i^k\right)}{n^2 \varepsilon^2} = 1 - \frac{\sum_{i=1}^n D(X_i^k)}{n^2 \varepsilon^2} = 1 - \frac{n D(X^k)}{n^2 \varepsilon^2} \rightarrow 1 \end{aligned}$$

$$\lim_{n \rightarrow \infty} P\left\{\left|\frac{1}{n} \sum_{i=1}^n X_i^k - E(X^k)\right| < \varepsilon\right\} = 1$$

# 例7 正态分布总体 $N(\mu, \sigma^2)$ 的样本方差 $S^2$ 是总体方差 $\sigma^2$ 的一致估计

证明 :  $E(S^2) = \sigma^2$  故 ,

$$1 \geq P\{|S^2 - \sigma^2| < \varepsilon\} = P\{|S^2 - E(S^2)| < \varepsilon\} \geq 1 - \frac{D(S^2)}{\varepsilon^2}$$

其中 ,  $D(S^2) = D\left[\frac{(n-1)S^2}{\sigma^2} \cdot \frac{\sigma^2}{n-1}\right]$

$$= \left(\frac{\sigma^2}{n-1}\right)^2 \cdot D\left[\frac{(n-1)S^2}{\sigma^2}\right] = \left(\frac{\sigma^2}{n-1}\right)^2 \cdot 2(n-1) = \frac{2\sigma^4}{n-1}$$

故 ,  $1 \geq P\{|S^2 - \sigma^2| < \varepsilon\} \geq 1 - \frac{2\sigma^4}{(n-1)\varepsilon^2}$

$$\lim_{n \rightarrow \infty} P\{|S^2 - \sigma^2| < \varepsilon\} = 1$$

**例8**  $X \sim f(x; \theta) = \begin{cases} \frac{1}{\theta} e^{-\frac{x}{\theta}} & x > 0, \\ 0 & x \leq 0 \end{cases} \quad \theta > 0 \text{ 为常数}$

则  $\bar{X}$  是  $\theta$  的无偏、一致估计量.

**证** 由例3 知  $\bar{X}$  是  $\theta$  的无偏估计量.

$$1 \geq P\left\{\left|\bar{X} - \theta\right| < \varepsilon\right\} \geq 1 - \frac{D(\bar{X})}{\varepsilon^2} = 1 - \frac{\theta^2}{n\varepsilon^2}$$

$$\lim_{n \rightarrow \infty} P\left\{\left|\bar{X} - \theta\right| < \varepsilon\right\} = 1$$

所以  $\bar{X}$  是  $\theta$  的一致估计量, 证毕.

## § 8.3 区间估计

**引例** : 已知  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2$ 已知,  $\mu$ 未知

$x_1, x_2, \dots, x_n$ 是一组样本值。

估计未知参数 $\mu$

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow \frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0, 1)$$

则  $P\left(\left|\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}\right| > z_{1-\alpha/2}\right) = \alpha$

故  $P\left(\left|\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}\right| \leq z_{1-\alpha/2}\right) = 1 - \alpha$

即  $P\left(\bar{X} - z_{1-\alpha/2}\sqrt{\sigma^2/n} \leq \mu \leq \bar{X} + z_{1-\alpha/2}\sqrt{\sigma^2/n}\right) = 1 - \alpha$

称随机区间  $\left(\bar{X} - z_{1-\alpha/2}\sqrt{\sigma^2/n}, \bar{X} + z_{1-\alpha/2}\sqrt{\sigma^2/n}\right)$

为未知参数  $\mu$  的置信度为  $1 - \alpha$  的置信区间.

# 置信区间的的意义

$$\left( \bar{X} - z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}}, \quad \bar{X} + z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}} \right)$$

反复抽取容量为n的样本，都可得到一个区间，这个区间可能包含未知参数  $\mu$  的真值，也可能不包含未知参数的真值，包含真值的区间占  $1-\alpha$ .

$$\bar{X} - z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}} \text{ —— } \mu \text{ 的置信下限}$$

$$\bar{X} + z_{1-\alpha/2} \sqrt{\frac{\sigma^2}{n}} \text{ —— } \mu \text{ 的置信上限}$$

$$1 - \alpha \text{ —— 置信度}$$

## 置信区间的定义

设  $\theta$  是一个待估计的参数,  $\alpha$  是一给定的数, ( $0 < \alpha < 1$ ). 若能找到两个统计量

$$\hat{\theta}_1(X_1, X_2, \dots, X_n), \quad \hat{\theta}_2(X_1, X_2, \dots, X_n)$$

使得  $P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$

则称随机区间  $(\hat{\theta}_1, \hat{\theta}_2)$  为参数  $\theta$  的置信度为  $1 - \alpha$  的置信区间, 分别称  $\hat{\theta}_1, \hat{\theta}_2$  为置信下限与置信上限,  $1 - \alpha$  称为置信水平或置信度.

## 几点说明

$$P(\hat{\theta}_1 < \theta < \hat{\theta}_2) = 1 - \alpha$$

□ 置信区间的长度  $\hat{\theta}_2 - \hat{\theta}_1$  反映了估计的精度

$\hat{\theta}_2 - \hat{\theta}_1$  越小, 估计的精度越高.

例 :  $(\bar{X} + z_{1-\alpha/2} \sqrt{\sigma^2/n}) - (\bar{X} - z_{1-\alpha/2} \sqrt{\sigma^2/n}) = 2 \cdot z_{1-\alpha/2} \sqrt{\sigma^2/n}$

□  $\alpha$  反映了估计的可靠程度,  $\alpha$  越小, 越可靠.

$\alpha$  越小,  $1 - \alpha$  越大, 估计的可靠程度越高, 但  
这时,  $\hat{\theta}_2 - \hat{\theta}_1$  往往增大, 因而估计的精度降低.

□  $\alpha$  确定后, 置信区间 的选取方法不唯一, 常  
选长度最小的一个.

# 求置信区间的步骤

## □ 寻找一个样本的函数

$g(X_1, X_2, \dots, X_n, \theta)$  — 称为**枢轴量**

例如  $\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}} = g(X_1, X_2, \dots, X_n, \mu) \sim N(0, 1)$

它含有待估参数, 不含其它未知参数, 它的分布已知, 且分布不依赖于待估参数 (常由  $\theta$  的点估计出发考虑).

□ 给定置信度  $1 - \alpha$ , 定出两个常数  $a, b$ , 使得

$$P(a < g(X_1, X_2, X_n, \theta) < b) = 1 - \alpha$$

例如

$$P\left(\left|\frac{\bar{X} - \mu}{\sqrt{\sigma^2/n}}\right| \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

□ 由  $a < g(X_1, X_2, X_n, \theta) < b$  解出

$$\underline{\theta}(X_1, X_2, \dots, X_n) \quad \bar{\theta}(X_1, X_2, \dots, X_n)$$

得置信区间  $(\underline{\theta}, \bar{\theta})$

例如  $(\bar{X} - z_{1-\alpha/2} \sqrt{\sigma^2/n}, \bar{X} + z_{1-\alpha/2} \sqrt{\sigma^2/n})$

# 置信区间常用公式

(一) 一个正态总体  $X \sim N(\mu, \sigma^2)$  的情形

(1) 方差  $\sigma^2$  已知,  $\mu$  的置信区间

$$(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}) \quad \dots \dots \dots \quad (1)$$

**推导** 由  $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$  选取枢轴量

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0, 1)$$

$$\text{由 } P\left(\left|\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}}\right| > z_{1-\alpha/2}\right) = \alpha$$

$$\text{得 } P\left(\left|\frac{\bar{X} - \mu}{\sqrt{\frac{\sigma^2}{n}}}\right| \leq z_{1-\alpha/2}\right) = 1 - \alpha$$

$$\text{即 } P\left(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha$$

故  $\mu$  的置信度为  $1 - \alpha$  的置信区间为

$$(\bar{X} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}})$$

## (2) 方差 $\sigma^2$ 未知, $\mu$ 的置信区间

$$\left( \bar{X} - t_{1-\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{1-\frac{\alpha}{2}}(n-1) \frac{S}{\sqrt{n}} \right) \dots \dots \dots \quad (2)$$

**推导** 选取枢轴量  $T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim T(n-1)$

由  $P \left( \left| \frac{\bar{X} - \mu}{S/\sqrt{n}} \right| \geq t_{1-\frac{\alpha}{2}}(n-1) \right) = \alpha$

$$\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = S^2$$

知  $P\left(\left|\frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}}\right| < t_{1-\frac{\alpha}{2}}(n-1)\right) = 1 - \alpha$

$$P\left(\bar{X} - t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}} < \mu < \bar{X} + t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}}\right) = 1 - \alpha$$

故  $\mu$  的置信区间为

$$\left(\bar{X} - t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}}, \bar{X} + t_{1-\frac{\alpha}{2}}(n-1)\frac{S}{\sqrt{n}}\right)$$

**用到：**设总体  $X \sim N(\mu, \sigma^2)$ ， $(X_1, X_2, \dots, X_n)$  是总体  $X$  的样本， $S^2$  为样本方差，证明：

$$T = \frac{\bar{X} - \mu}{\frac{S}{\sqrt{n}}} \sim t(n-1)$$

证明： $X_i \sim N(\mu, \sigma^2)$

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\frac{\bar{X} - \mu}{\sigma / \sqrt{n}} \sim N(0,1) \quad \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

$$\frac{\bar{X} - \mu}{S / \sqrt{n}} = \frac{\frac{\bar{X} - \mu}{\sigma / \sqrt{n}}}{\sqrt{\frac{(n-1)S^2}{\sigma^2}}} \sim t(n-1)$$

### (3) 当 $\mu$ 已知时, 方差 $\sigma^2$ 的 置信区间

取枢轴量  $Q = \sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$

由概率

$$P \left( \chi_{\frac{\alpha}{2}}^2(n) < \frac{\sum_{i=1}^n (X_i - \mu)^2}{\sigma^2} < \chi_{1-\frac{\alpha}{2}}^2(n) \right) = 1 - \alpha$$

得  $\sigma^2$  的置信度为  $1 - \alpha$  置信区间为

$$\left( \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\frac{\alpha}{2}}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\frac{\alpha}{2}}^2(n)} \right) \dots \dots \quad (3)$$

#### (4) 当 $\mu$ 未知时, 方差 $\sigma^2$ 的置信区间

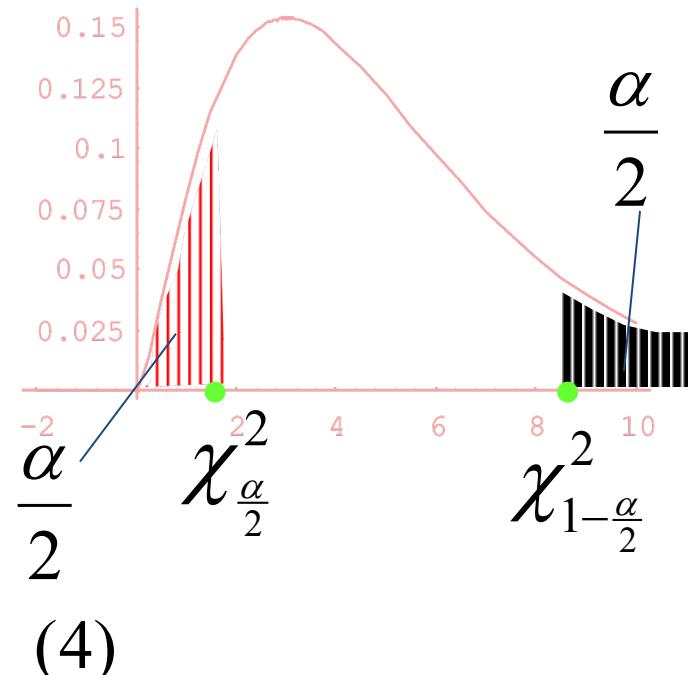
P177  
Th3

选取  $K = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$  则由

$$P\left(\chi_{\frac{\alpha}{2}}^2 < \frac{(n-1)S^2}{\sigma^2} < \chi_{1-\frac{\alpha}{2}}^2\right) = 1 - \alpha$$

得  $\sigma^2$  的置信区间为

$$\left( \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)} \right) \dots\dots$$



**例1** 某工厂生产一批滚珠, 其直径  $X$  服从正态分布  $N(\mu, \sigma^2)$ , 现从某天的产品中随机抽取6件, 测得直径为

15.1 , 14.8 , 15.2 , 14.9 , 14.6 , 15.1

- (1) 若  $\sigma^2=0.06$ , 求  $\mu$  的置信度为95%的置信区间;
- (2) 若  $\sigma^2$ 未知,求  $\mu$  的置信度为95%的置信区间;
- (3) 求方差  $\sigma^2$ 的置信度为95%的置信区间.

**解** (1)若 $\sigma^2=0.06$ , 求 $\mu$ 的置信度为95%的置信区间;

$$(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}) \text{-----}$$

$$\sigma^2=0.06 \quad n=6 \quad 1-\alpha=0.95$$

$$z_{1-\frac{\alpha}{2}} = z_{1-0.025} = 1.96$$

由给定数据算得  $\bar{x} = \frac{1}{6} \sum_{i=1}^6 x_i = 14.95$

由公式(1)得 $\mu$ 的置信区间为

$$(\bar{x} - z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}}, \quad \bar{x} + z_{1-\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}})$$

$$=(14.75, \quad 15.15)$$

(2) 若  $\sigma^2$  未知, 求  $\mu$  的置信度为 95% 的置信区间

$$(\bar{x} - \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1), \quad \bar{x} + \frac{s}{\sqrt{n}} t_{1-\frac{\alpha}{2}}(n-1)) \quad \text{--- --- --- --- ---}$$

查表得  $t_{1-0.025}(5) = 2.5706$

由给定数据算得  $\bar{x} = 14.95$

$$s^2 = \frac{1}{5} \left( \sum_{i=1}^6 x_i^2 - 6\bar{x}^2 \right) = 0.051. \quad s = 0.226$$

由公式 (2) 得  $\mu$  的置信区间为

$$(\bar{x} - \frac{s}{\sqrt{6}} t_{0.025}(5), \quad \bar{x} + \frac{s}{\sqrt{6}} t_{0.025}(5)) = (14.71, \quad 15.187)$$

(3) 求方差 $\sigma^2$ 的置信度为95%的置信区间

$$\left( \frac{(n-1)S^2}{\chi_{1-\frac{\alpha}{2}}^2(n-1)}, \frac{(n-1)S^2}{\chi_{\frac{\alpha}{2}}^2(n-1)} \right) \text{-----}$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = 0.051.$$

查表得  $\chi_{0.025}^2(5) = 0.831, \quad \chi_{0.975}^2(5) = 12.833$

由公式(4)得  $\mu$  的置信区间为

$$\left( \frac{5S^2}{\chi_{0.975}^2(5)}, \frac{5S^2}{\chi_{0.025}^2(5)} \right) = (0.0199, 0.3069)$$

## (二) 单侧置信区间

**定义** 对于给定的  $\alpha (0 < \alpha < 1)$ ,  $\theta$  是待估参数

$(X_1, X_2, \dots, X_n)$  是总体  $X$  的样本,

若能确定一个统计量

$$\underline{\theta} = \underline{\theta}(X_1, X_2, \dots, X_n) \quad (\text{或 } \bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n))$$

使得  $P(\theta > \underline{\theta}) = 1 - \alpha$  ( $\text{或 } P(\theta < \bar{\theta}) = 1 - \alpha$ )

则称  $(\underline{\theta}, +\infty)$  ( $\text{或 } (-\infty, \bar{\theta})$ )

为置信度为  $1 - \alpha$  的单侧置信区间.

$\underline{\theta}$  — 单侧置信下限

$\bar{\theta}$  — 单侧置信下限

**例3** 已知灯泡的寿命 $X$ 服从正态分布, 从灯泡中随机地抽取 5 只作寿命试验, 测得寿命(以小时记)为

1050, 1100, 1120, 1250, 1280

求灯泡寿命均值的置信度为0.95的单侧置信下限与灯泡寿命方差的置信度为0.95的单侧置信上限

**解**

$X \sim N(\mu, \sigma^2)$ ,  $\mu, \sigma^2$ 未知

$$(1) \text{ 选取枢轴量 } \frac{\bar{X} - \mu}{\sqrt{n}} \sim t(n-1)$$

$$\text{故 } P\left(\frac{\bar{X} - \mu}{\sqrt{n}} \leq t_{1-\alpha}(n-1)\right) = 1 - \alpha$$

$$\text{即 } P\left(\mu \geq \bar{X} - t_{1-\alpha}(n-1) \cdot \sqrt{n}\right) = 1 - \alpha$$

$$n = 5, \quad \bar{x} = 1160, \quad s^2 = \frac{1}{4} \left( \sum_{i=1}^5 x_i^2 - 5\bar{x} \right) = 9950$$

$$t_{1-\alpha}(n-1) = t_{1-0.05}(4) = 2.1318$$

$$\underline{\mu} = \bar{x} - t_{1-0.05}(4) \times \frac{s}{\sqrt{5}} = 1064.9$$

(2) 选取枢轴量  $\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$

故  $P\left(\frac{(n-1)S^2}{\sigma^2} > \chi_{\alpha}^2(n-1)\right) = 1 - \alpha$

即  $P\left(\sigma^2 < \frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}\right) = 1 - \alpha$

$$n = 5, \quad S^2 = \frac{1}{4} \left( \sum_{i=1}^5 x_i^2 - 5\bar{x} \right) = 9950$$

$$\chi_{0.05}^2(4) = 0.711$$

$$\overline{\sigma^2} = \frac{4S^2}{\chi_{0.05}^2(4)} = 55977$$